基于注意力机制的中文问答检索增强方法

摘要：本文提出一种面向中文问答的轻量级检索增强方法。该方法在稠密检索之后引入段落级重排序，并利用注意力机制对证据句进行加权。在三个中文问答数据集上，准确率比强基线提升 ４．２ 个百分点，推理延迟仅增加 １１ 毫秒。消融实验表明，重排序模块贡献了 ３．１ 个百分点，证据加权贡献了 １．１ 个百分点。

１ 引言

中文问答系统需要在海量文档中定位证据句。现有方法多依赖单路稠密检索，在长文档场景下召回率高但排序质量不足。我们观察到，问题与证据句之间的注意力分布高度集中于少数关键词，因此可以用轻量注意力对候选段落重排序。

２ 方法

我们先用双塔模型召回前 ５０ 个段落，再用交叉编码器计算问题与段落的匹配分数，最后按分数加权拼接证据句。训练时使用对比学习目标，温度系数设为 ０．０５。

３ 实验

实验在中文问答基准上进行，评价指标为准确率与平均延迟。基线为 ＢＭ２５ 与稠密检索的组合。结果显示我们的方法在保持低延迟的同时显著提升准确率。